

01_data_exploration

March 24, 2026

1 01 Data Exploration

This notebook is for quick inspection of extracted page images, layout variation, and likely failure cases for the printed OCR baseline.

```
[3]: from pathlib import Path
      from PIL import Image
      import matplotlib.pyplot as plt
```

```
page_dir = Path('../data/page_images')
page_paths = sorted(page_dir.glob('*.png'))
len(page_paths), page_paths[:5]
```

```
[3]: (1395,
      [PosixPath('../data/page_images/buendia_instruccion_page_0001.png'),
       PosixPath('../data/page_images/buendia_instruccion_page_0002.png'),
       PosixPath('../data/page_images/buendia_instruccion_page_0003.png'),
       PosixPath('../data/page_images/buendia_instruccion_page_0004.png'),
       PosixPath('../data/page_images/buendia_instruccion_page_0005.png')])
```

```
[4]: sample_path = page_paths[0]
      image = Image.open(sample_path)
      plt.figure(figsize=(10, 14))
      plt.imshow(image)
      plt.axis('off')
      plt.title(sample_path.name);
```

Libro del sam - t

INSTRUCCION

D E
CHRISTIANA , Y POLITICA

CORTEŠANIA CON DIOS,

Y

CON LOS HOMBRES.

DISPUESTA , PRIMARIAMEN-
te , para los Señores Colegiales del
Imperial Colegio de Nuestra Señora,
y Santiago de Cordellas , de la
Compañía de JESUS de
Barcelona.

SU AUTHOR

Don Fausto Agustin de Buendia.

Quien la dedica al infinitamente
amable Niño JESUS.

CON LICENCIA.

GERONA: Por JAYME BRÓ , Im-
preffor, y Librero, Año. 1740.

